



Expansion internationale de l'EdTech "academy"



Objectif : Identifier les pays à fort potentiel pour academy, une start-up proposant des contenus à destination des lycéens et étudiants.

Mission : Analyser les données de la Banque mondiale pour repérer les opportunités d'expansion à fort impact.

Sources de Données



BASES DE DONNÉES EDSTATS (BANQUE MONDIALE)

Methode : Utiliser les données publiques de la Banque mondiale pour fournir des insights exploitables.

- EdStatsData.csv : indicateurs éducatifs annuels par pays (886 930 lignes)
- EdStatsSeries.csv : métadonnées des indicateurs
- EdStatsCountry.csv : informations sur les pays
- Fichiers auxiliaires : Country-Series, FootNotes

Nettoyage initial des données



STRUCTURATION DES DONNÉES DE BASE

- Suppression colonnes vides / doublons
- Filtrage des faux pays (ex. : "Arab World", "High income")
- Focus uniquement sur les pays exploitables pour academy

Réduction par pertinence métier




FOCUS SUR LES CATÉGORIES CLÉS DES INDICATEURS

Sélection des thématiques prioritaires pour Academy :

- Secondary et Tertiary Education (clientèle cible).
- ICT/Internet Users (accès numérique).
- Population 15–24 (cible démographique).
- GDP, GNI, PPP (capacité économique).

NETTOYAGE TEMPOREL

- Focus sur les années 2000 à 2016.
- Suppression des colonnes d'années sans aucune donnée.




Le choix des indicateurs

ÉVALUATION DE LA COMPLÉTUDE DES DONNÉES

Calcul de proportions :

- Proportion d'indicateurs avec valeurs par année → stabilité temporelle.
- Proportion d'années complètes par indicateur → robustesse des indicateurs.
- Nombre de pays renseignés par indicateur/année → représentativité géographique.

Restructuration du jeu de données



MANIPULATION DU DATASET

- Melt() pour format long (pays, indicateur, année)
- Pivot_table() pour moyenne 2000-2016
- Format final : pays (lignes) x indicateurs (colonnes)


RÉSULTAT

Table resultante avec :

- Lignes = pays.
- Colonnes = indicateurs.
- Valeurs = moyennes sur 17 ans.

Analyse de la redondance

(Exemple de matrice de Pearson)




CORRÉLATION ENTRE INDICATEURS

- Calcul de la matrice de corrélation de Pearson et Spearman
- Suppression des indicateurs corrélés (coeff >0.70)
- Passage de 13 à 6 indicateurs

Indicateurs finaux retenus


6 INDICATEURS STRATÉGIQUES

- 1.IT.NET.USER.P2 : Utilisateurs d'Internet pour 100 personnes
- 2.NY.GDP.MKTP.CD : PIB total (USD)
- 3.NY.GNP.MKTP.CD : RNB total (USD)
- 4.SE.SEC.PRIV.ZS : % d'élèves du secondaire dans le privé
- 5.SP.POP.1524.TO.UN : Population 15-24 ans (milliers)
- 6.UIS.TE_100000.56 : Etudiants dans l'enseignement supérieur / 100k hab.



Visualisation statistique

Distribution de l'indicateur IT.NET.USER.P2 qui comptabilise le nombre d'utilisateurs internet par pays



LA DISTRIBUTION

- Describe() : moyenne, min, max, écart-type
- Displot() : détection des outliers et des biais
- Objectif : identifier les pays performants

Méthode quantitative (Top 5)



PRIORISATION DE CERTAINS PAYS

- Top 5 pays par indicateur (méthode nlargest)
- Comptage des occurrences par pays
- Pays les plus fréquents dans les top 5 = prioritaires pour l'analyse

Pays recommandés



PAYS LES PLUS RÉCURRENTS DANS LES TOP 5 PAR INDICATEUR

- États-Unis (4 occurrences)

NY.GDP.MKTP.CD

NY.GNP.MKTP.CD

SP.POP.1524.TO.UN

UIS.TE_100000.56


- Chine (3 occurrences)

NY.GDP.MKTP.CD

NY.GNP.MKTP.CD

SE.SEC.PRIV.ZS

Résultats finaux




PROPOSITIONS

- Cibler 2 pays prioritaires pour le déploiement d'academy à l'international (USA, Chine)

Justification :

- Connectivité élevée
- Population jeune nombreuse
- Niveaux économiques solides
- Structures éducatives développées



Vers une implantation réussie ?

Synthèse

- Démarche rigoureuse, métier et statistique.
- Passage de 886 000 lignes à un tableau synthétique à forte valeur ajoutée.
- Indicateurs sélectionnés pour leur complémentarité stratégique.

Recommandations :

- Préparer des études de marché spécifiques sur ces pays.

Compléter l'analyse avec :

- Données internes : coûts, trafic, taux de conversion.
- Données concurrentielles : part de marché locale des EdTech.



La pertinence des données

Une mine d'or en termes de données

- Un nombre impressionnant de données récupérées à travers le monde
- Elles permettent de faire un portrait global de l'éducation dans le monde
- Indicateurs sélectionnés pour leur complémentarité stratégique

Limites :

- Grand nombre de données manquantes
- Des données assez peu exploitables commercialement
- Moyennement pertinente dans un cadre orienté business